

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 6297

**Primjena konstruktivnog
optimizacijskog algoritma na
problem rasporeda studenata**

Martin Čekada

Zagreb, lipanj 2019.

Zagreb, 14. ožujka 2019.

ZAVRŠNI ZADATAK br. 6297

Pristupnik: **Martin Čekada (0036499611)**
Studij: Računarstvo
Modul: Računarska znanost

Zadatak: **Primjena konstruktivnog optimizacijskog algoritma na problem rasporeda studenata**

Opis zadatka:

Problemi raspoređivanja u svakodnevnom životu izuzetno su česti i uobičajeno su visoke računske složenosti. Stoga su načini njihovog rješavanja od posebnog interesa.

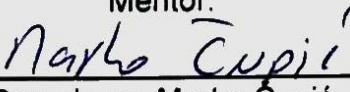
U okviru ovog završnog rada potrebno je proučiti konstruktivističke optimizacijske pristupe koji rješenje grade komponentu po komponentu, a koji se temelje na vjerojatnosnom modelu. Potrebno je navesti formalnu specifikaciju jednog konkretnog problema raspoređivanja studenata te za njega napraviti prototipnu programsku implementaciju temeljenu na odabranom algoritmu. Potrebno je provesti analizu napisanog algoritma te komentirati dobivena rješenja. Također, u okviru rada potrebno je razmotriti utjecaj različitih kriterija koji se mogu uzeti u obzir prilikom izrade optimalnog rasporeda.

Radu priložiti izvorni kod razvijenih postupaka uz potrebna objašnjenja i dokumentaciju. Predložiti pravce budućeg razvoja. Citirati korištenu literaturu i navesti dobivenu pomoć.


Zadatak uručen pristupniku: 15. ožujka 2019.

Rok za predaju rada: 14. lipnja 2019.

Mentor:


Doc. dr. sc. Marko Čupić

Djelovoda:


Izv. prof. dr. sc. Tomislav Hrkać

Predsjednik odbora za
završni rad modula:


Doc. dr. sc. Marko Čupić

Zahvaljujem mentoru doc. dr. sc. Marku Čupiću na pomoći i mentoriranju pri izradi ovog rada. Zahvaljujem i obitelji i prijateljima na podršci i razumijevanju.

SADRŽAJ

1. Uvod	1
2. Pregled područja	2
2.1. Optimizacijski algoritmi	3
2.1.1. Mađarski algoritam	4
2.1.2. Algoritam kolonije mrava	6
3. Opis algoritma	8
3.1. Opći matematički model algoritma	8
3.2. Generalizirani algoritam	9
3.2.1. Početak	9
3.2.2. Uzorkovanje	10
3.2.3. Ocjenjivanje	10
3.2.4. Ažuriranje	10
4. Primjena na problem vodećih jedinica	12
5. Primjena na problem izrade rasporeda laboratorijskih vježbi	14
5.1. Formalna definicija problema	15
5.2. Inicijalna distribucija	15
5.3. Funkcija dodjeljivanja kazne	16
5.4. Heuristike	16
5.4.1. Rebalansiranje trenutne distribucije	19
5.4.2. Redistribucija vjerojatnosti prepunjenih termina	20
5.5. Nadogradnje algoritma prioriternim redom	21
5.6. Rad algoritma	22
6. Vrednovanje algoritma	24
6.1. Razvoj algoritma	24

6.2.	Utjecaj parametara na rad algoritma	25
6.2.1.	Veličina uzorka	26
6.2.2.	Koeficijent prepunjenja	26
6.2.3.	Koeficijent izgladivanja	27
6.2.4.	Koeficijent prioritetnog reda	27
6.2.5.	Veličina prioritetnog reda	28
6.3.	Opis testnih primjera	28
6.4.	Rezultati	29
6.4.1.	Rezultati rasporeda za kolegij Digitalne logike	31
6.4.2.	Rezultati rasporeda za kolegij Objektno orijentiranog progra- miranja	32
7.	Zaključak	34
	Literatura	35

1. Uvod

Problem izrade rasporeda je čest problem u školstvu, a i šire gledano u današnjem svijetu. Izrada jednostavnijih rasporeda, poput rasporeda sati za razrede u osnovnoj školi se može riješiti i često se u hrvatskoj svakodnevnici rješava *ručno*. To je moguće jer su učenici grupirani u jedinstvene cjeline (razrede) te se zapravo ne radi o izradi rasporeda učenika, nego o izradi rasporeda razreda (kojih je naravno znatno manje nego učenika). U većim ustanovama, poput Fakulteta elektrotehnike i računarstva, izrada rasporeda je znatno kompliciranija. U želji da se ubrza i pojednostavni izrada rasporeda, izrada se prepušta računalima. Usprkos velikoj procesorskoj snazi koju današnja računala posjeduju i dalje nije moguće u realnom vremenu sa sigurnošću odrediti optimalan raspored. Zbog toga problem izrade rasporeda pripada u skupinu optimizacijskih problema. Prilikom rješavanja optimizacijski problem nije moguće uvijek pronaći optimalno rješenje te se zato rješavanje problema zaustavlja jednom kada se pronađe dovoljno dobro rješenje. Ovaj rad se bavi izradom rasporeda za laboratorijske vježbe na Fakultetu elektrotehnike i računarstva. Cilj rada je primijeniti konstruktivistički optimizacijski algoritam na izradu rasporeda.

Ostatak rada je organiziran kako slijedi. U poglavlju 2 je dan pregled povezanih područja i pojedini optimizacijski algoritmi. U poglavlju 3 je opisan algoritam predstavljen u radu Wu i Kolonko (2014). Primjena opisanog algoritma na problem vodećih jedinica je dana u poglavlju 4. U poglavlju 5 je prikazana primjena algoritma na problem izrade rasporeda laboratorijskih vježbi na Fakultetu elektrotehnike i računarstva. Vrednovanje rada algoritma je dano u poglavlju 6, dok je u posljednjem poglavlju dan zaključak.

2. Pregled područja

Problemi raspoređivanja su specijalizacija transportnih problema te su jedni od temeljnih optimizacijskih problema. Općenito gledano, problemi raspoređivanja bi se mogli definirati kako je dano u nastavku.

Problem se sastoji od agenata i zadataka. Svakom agentu može biti dodijeljen bilo koji od zadataka uz određenu cijenu, a cijena može varirati ovisno o uparivanju agenta i zadatka. Potrebno je svakom agentu dodijeliti zadatak tako da ukupna cijena dodjeljivanja bude minimalna.

Ovakvi problemi bi se mogli pokušati riješiti tako da se generira svaka kombinacija dodjeljivanja agenata i zadataka te da se odredi dodjeljivanje s najmanjom cijenom. Ukoliko bi se dodjeljivanje vršilo za n agenata i n zadataka, složenost dodjeljivanja bi bila $n!$. Porastom broja n vrijeme potrebno da se na ovaj način odredi dodjeljivanje s najmanjom cijenom vrlo brzo postaje preveliko da bi se izračunalo u realnom vremenu. Zbog toga kod problema raspoređivanja (i općenito optimizacijskih problema) ne tražimo optimalno rješenje iscrpno, nego različitim pristupima pokušavamo pronaći dovoljno dobro rješenje. U nastavku slijedi opis nekih specifičnih problema raspoređivanja.

Primjer 1.¹ Zadana je funkcija $g(x, y, z)$ nad domenom $[-300, 500] \times [-300, 500] \times [-300, 500] \subset \mathbb{R} \times \mathbb{R} \times \mathbb{R}$. Pronaći točku (x, y, z) za koju funkcija g poprima maksimalnu vrijednost.

Primjer 2. Satničaru su na raspolaganju popis kolegija koji se predaju, popis studenata i njihov izbor kolegija, popis slobodnih dvorana i termina, željeni tjedni broj predavanja za svaki od kolegija te popis nastavnika koji predaju određene kolegije. Satničar treba zadovoljiti sljedeće uvjete:

- svi studenti imaju zakazana sva predavanja i mogu ih slušati bez kolizija,

¹Primjer preuzet iz (Čupić, 2013)

- niti jedan nastavnik ne drži više predavanja istovremeno,
- niti u jednu dvoranu ne smije biti smješteno više studenata nego što je kapacitet dvorane te
- niti u jednu prostoriju ne smiju biti smještena dva predavanja istovremeno.

Također, bilo bi poželjno kada bi satničar osigurao da:

- student u danu ima barem dva predavanja ili niti jedno,
- student ima minimalan broj rupa u danu,
- nastavnik ima minimalan broj rupa u danu te
- nastavnik ima minimalan broj promjena dvorana u danu.

Primjer 3. Primjer u nastavku je pojednostavljen i prilagođen organizaciji međuispita na Fakultetu elektrotehnike i računarstva. Prilikom izrade ispita dostupni su podaci o predmetima za koje treba održati ispit, podaci o slobodnim terminima te podaci o studentima i ispitima kojima oni mogu pristupiti. Potrebno je izraditi raspored međuispita tako da niti jedan student ne piše istovremeno dva ispita, da svaki student može pristupiti svakom svojem ispitu te tako da se niti u jednoj dvorani ne pišu istovremeno dva ispita. Bilo bi poželjno da student ima što ravnomjernije raspoređen broj slobodnih dana između ispita.

Na prethodnim primjerima se može primijetiti da se neki od uvjeta moraju ispuniti, dok su neki samo poželjni. To su tvrda (engl. *hard*) i meka (engl. *soft*) ograničenja (engl. *constraints*). Tvrda ograničenja moraju biti ispunjena kako bi rješenje bilo prihvatljivo (npr. u primjeru 2 ne može konačno rješenje biti ono u kojem nastavnik istovremeno predaje u dva termina). S druge strane, meka ograničenja nisu obavezna, ali što su ona ispunjenija, to je rješenje bolje.

Kako je u početku poglavlja ustanovljeno da se ovakvi problemi ne mogu rješavati tehnikom grube sile (engl. *brute force*), postavlja se pitanje na koje se načine u realnom vremenu može pronaći dovoljno dobro rješenje. Neki od optimizacijskih algoritama korišteni za rješavanje problema raspoređivanja su navedeni u nastavku.

2.1. Optimizacijski algoritmi

U ovom poglavlju su navedena dva primjera algoritama koji se mogu primijeniti na probleme raspoređivanja. Konstruktivni optimizacijski algoritam je detaljno opisan u narednim poglavljima, a postoji još mnoštvo drugih algoritama koji se mogu koristiti (algoritam roja čestica, algoritmi umjetnih imunoloških sustava, genetski algoritmi

itd.). Svaki od algoritama ima svoje prednosti i nedostatke te je prikladniji za određenu specijalizaciju problema, dok za drugu vrstu problema daje slabije rezultate. Ova tvrdnja je poznata kao teorem *no-free-lunch* kojeg su Wolpert i Macready dokazali u svojim radovima, a u originalu glasi² kako je navedeno u nastavku.

All algorithms that search for an extremum of a cost function perform exactly the same, according to any performance measure, when averaged over all possible cost functions. In particular, if algorithm A outperforms algorithm B on some cost functions, then loosely speaking there must exist exactly as many other functions where B outperforms A.

2.1.1. Mađarski algoritam

Algoritam je razvio i objavio Harold Kuhn 1955. godine, a nadjenao mu je ime *mađarski* jer se algoritam velikom mjerom oslanja na rad dvaju mađarskih matematičara Dénes Kőnig i Jenő Egerváry. Algoritam je namijenjen raspoređivanju n poslova na n radnika pri čemu jedan radnik može obavljati samo jedan posao. Dakako, problem bi se mogao preslikati na prethodno naveden primjer 1 ili na raspoređivanje studenata u kojem je svakom studentu pridružen različit termin (ovo je češći slučaj kada se radi raspored za usmene ispite).

Vremenska složenost ovog algoritma je $\mathcal{O}(n^3)$, a algoritam koristi sljedeći teorem: *Ako svakom elementu bilo kojeg retka ili stupca matrice kazne dodamo ili oduzmemo neki broj, tada je optimalno raspoređivanje za rezultatnu matricu također optimalno i za prvotnu matricu.* Pritom se matricom kazne smatra matrica čiji redci predstavljaju radnike, stupci predstavljaju poslove, a vrijednost matrice na mjestu $C(i, j)$ predstavlja cijenu dodjeljivanja radniku i posao j . Koraci algoritma slijede.

1. Za svaki redak matrice, pronađi najmanji element i oduzmi ga od svakog elementa u njegovom retku.
2. Ponovi korak 1. za svaki stupac.
3. Prekrij sve nule u matrici koristeći minimalan broj horizontalnih i vertikalnih linija.
4. Test optimalnosti: ako je minimalan broj linija potrebnih da se prekriju sve nule u matrici jednak n , tada je optimalno rješenje moguće i završavamo s izvođenjem

²Citat preuzet iz Čupić (2013)

algoritma. Ako je broj linija manji on n , tada optimalno rješenje nije pronađeno te nastavljamo na korak 5.

5. Pronađi najmanji element matrice koji nije prekriven niti jednom linijom. Oduzmi taj element od svakog neprekrivenog retka i potom ga dodaj svakom prekrivenom stupcu. Vрати se na korak 3.

Pogledajmo to sada na primjeru raspoređivanja poslova utovara robe, transporta robe te istovara robe među radnicima Petrom, Ivanom i Markom. Neka je cijena pri-djeljivanja poslova između radnika određena tablicom 2.1.

Tablica 2.1: Tablica rasporeda poslova

	Utovar	Transport	Istovar
Petar	25	40	35
Ivan	40	60	35
Marko	20	40	25

Da bi izvođenje algoritma započelo, potrebno je prvo tablicu 2.1 zapisati matrično:

$$\begin{bmatrix} 25 & 40 & 35 \\ 40 & 60 & 35 \\ 20 & 40 & 25 \end{bmatrix}.$$

Potom može započeti izvršavanje algoritma.

1. Oduzmi najmanju vrijednost svakog retka.

$$\begin{bmatrix} 0 & 15 & 10 \\ 5 & 25 & 0 \\ 0 & 20 & 5 \end{bmatrix}$$

2. Prekrij sve nule minimalnim brojem linija.

$$\begin{bmatrix} \cancel{0} & \cancel{0} & \cancel{10} \\ \cancel{5} & 25 & \cancel{0} \\ 0 & 20 & 5 \end{bmatrix}$$

3. S obzirom na to da je broj linija potrebnih za prekrivanje svih nula jednak 3 optimalno rješenje je pronađeno.

Poslove treba raspodijeliti tako da Petar radi transport robe, Ivan istovar, a Marko utovar. Cijena takvog raspoređivanja je 95.

2.1.2. Algoritam kolonije mrava

Ovaj algoritam je inspiriran procesom kojim mravi pronalaze najkraći put između mravinjaka i hrane. Mravi se prilikom potrage za hranom ne služe svojim osjetilom vida, nego osjetilom feromona. Fermoni su kemijski tragovi koje mravi ostavljaju za sobom krećući se od mravinjaka do hrane i povratno. Intenzitet mirisa fermona slabi s vremenom ako tim putem ne prolaze mravi. Kako mravi na ovaj način pronalaze najkraći put između hrane i mravinjaka, intuitivno je jasno da je ovaj algoritam prikladan za pretraživanje grafova. Osim za pretraživanje grafova, algoritam kolonije mrava je uspješno primjenjivan na probleme izrade rasporeda³ te je u velikoj mjeri sličan konstruktivnom optimizacijskom algoritmu koji je tema ovog rada. Pseudo kod algoritma dan je u nastavku⁴.

Algorithm 1 Rad algoritma

```
repeat
  for svaki mrav do
    stvori rješenje
    vrednuj rješenje
  end for
  ispari feromonske tragove
  for svaki mrav do
    ažuriraj feromonske tragove
  end for
until kraj
```

Rješenje za svakog mrava se gradi tako da se odabire brid po brid kojima će mrav prolaziti (parovi bridova naravno moraju imati jednu zajedničku točku, odnosno mora se moći nakon prvog brida prijeći na drugi brid itd.). Odabir kojim bridom će mrav poći iz trenutnog čvora se određuje slučajnim proporcionalnim pravilom (engl. *random proportional rule*):

$$p_{ij}^k = \begin{cases} \frac{\tau_{ij}^\alpha \cdot \eta_{ij}^\beta}{\sum_{l \in N_k^i} \tau_{il}^\alpha \cdot \eta_{il}^\beta} & \text{ako } j \in N_k^i \\ 0 & \text{ako } j \notin N_k^i \end{cases}$$

pri čemu su α i β konstante, τ je intenzitet fermona na bridu, a η je heuristička informacija koliko je povoljno krenuti bridom. N_k^i predstavlja sve bridove kojima je

³Na primjer u radu Čupić (2019)

⁴Pseudokod preuzet iz Čupić (2019)

početni čvor trenutni čvor u kojem se mrav nalazi. Prije prve iteracije, sve vrijednosti τ se postavljaju na vrijednost koja je nešto veća od očekivane vrijednosti koju će mravi ostavljati u svakoj iteraciji. Za izračun se koristi izraz:

$$\tau_0 = \frac{m}{C^{nn}}$$

pri čemu je m broj mrava, a C^{nn} je procjena najkraćeg puta dobivena nekim jednostavnijim algoritmom.

Isparavanje feromonskih tragova se vrši tako da se trenutna vrijednost pomnoži s konstantnim koeficijentom prema izrazu:

$$\tau_{ij} \leftarrow \tau_{ij} \cdot (1 - \rho)$$

Mravi ažuriraju feromonske tragove proporcionalno dobroti rješenja koje su izgradili prema izrazu:

$$\tau_{ij} \leftarrow \tau_{ij} + \sum_{k=1}^m \Delta\tau_{ij}^k$$

pri čemu je:

$$\Delta\tau_{ij}^k = \begin{cases} \frac{1}{C^k} & \text{ako je } i-j \text{ na stazi mrava} \\ 0 & \text{ako nije na stazi} \end{cases}$$

3. Opis algoritma

Konstruktivni optimizacijski algoritmi su široko korišteni algoritmi za heurističku optimizaciju. Inačica konstruktivnog optimizacijskog algoritma koji je korišten u ovom radu se temelji na radu Wu i Kolonko (2014).

3.1. Opći matematički model algoritma

Promatramo problem s konačnim skupom izvodljivih rješenja S i funkcijom kazne $f : S \rightarrow \mathbb{R}$. Neka je skup S^* skup optimalnih rješenja te isključimo trivijalna rješenja, odnosno pretpostavim da $|S| > 1$ i da $S^* \neq S$. Neka se svako rješenje iz skupa S može zapisati kao konačan niz simbola $s = (s_1, \dots, s_L)$ iz skupa abecede $\mathbb{A} := a_1, \dots, a_K$. L je fiksna duljina rješenja. Model je generaliziran funkcijom izvodljivosti $C_i(y, a)$ koja dodjeljuje težinu svakom $a \in \mathbb{A}$ za svako moguće parcijalno rješenje y duljine i . Prema tome, ako je $C_i(y, a) = 0$, parcijalno rješenje y se ne može nastaviti tako da se na njega nadoda znak a . Što je vrijednost funkcije $C_i(y, a)$ veća, toliko je poželjnije da se niz nastavi znakom a pohlepno (engl. *greedy*) gledano. Pretpostavlja se da su vrijednosti funkcije normirane. Model gradi rješenja korak po korak dodajući nove simbole na desni kraj niza sve dok rješenje nije potpuno. Formalnije rečeno, definiramo skup R_i izvodljivih parcijalnih rješenja rekursivno kako slijedi: neka \diamond predstavlja prazan niz. Pretpostavljamo da je dano:

$$C_0(\diamond, \cdot) : \mathbb{A} \rightarrow [0, 1], \sum_{a \in \mathbb{A}} C_0(\diamond, a) = 1$$

što predstavlja poželjnost i izvodljivost znaka a na prvom mjestu rješenja. Nadalje definiramo:

$$R_1 := \{a \in \mathbb{A} | C_0(\diamond, a) > 0\}$$

Kao skup izvodljivih rješenja duljine 1. Pretpostavimo da je definiran skup R_i za neki $i \in 0, \dots, L - 1$ i da je dano:

$$C_i(y, \cdot) : \mathbb{A} \rightarrow [0, 1], \sum_{a \in \mathbb{A}} C_i(y, a) = 1, \text{ za svaki } y \in R_i$$

Neka (y, a) označava konkatiranje simbola $a \in \mathbb{A}$ na desni kraj parcijalnog rješenja y . Definiramo:

$$R_{i+1} := \{(y, a) | y \in R_i, a \in \mathbb{A}, C_i(y, a) > 0\}$$

i neka je $S := R_L$. Za svaki $y \in R_i, i \in \{0, \dots, L-1\}$, neka je

$$C_i(y) := \{a \in \mathbb{A} | C_i(y, a) > 0\}$$

bude potpora $C_i(y, \cdot)$.

Ovakva generalizacija modela ne postavlja gotovo nikakva ograničenja na optimizacijski problem. Odnosno, odgovarajućim odabirom \mathbb{A}, S i $C(y, a)$ svaki se problem može prilagoditi na ovaj model, no efikasnost može varirati. Model je razumnije koristiti u slučajevima kada je $|\mathbb{A}| \ll |S|$. Ovo dodatno potvrđuje teorem s kraja prethodnog poglavlja koji tvrdi da svaki algoritam ne daje jednako dobre rezultate na svakom problemu.

3.2. Generalizirani algoritam

U suštini, algoritam razvija distribuciju nad skupom $S = R_L$ svih izvodljivih rješenja dajući pritom veliku vjerojatnost optimalnim rješenjima iz skupa S^* . Neka $\mathbb{P}(\mathbb{A})$ označava skup svih vjerojatnosti nad skupom \mathbb{A} . Tada je $p \in \mathbb{P}(\mathbb{A})^L, p = (p(1), \dots, p(L))$ vjerojatnost nad skupom \mathbb{A}^L koja opisuje odabiranje rješenja $s = (s_1, \dots, s_L) \in \mathbb{A}^L$ pri čemu je L simbola s_1, \dots, s_L odabrano neovisno. Pritom je $p(i) = p(a; i)_{a \in \mathbb{A}} \in \mathbb{P}(\mathbb{A})$ je distribucija vjerojatnosti za simbol na i -toj lokaciji. Ulazni podaci za algoritam su:

1. funkcija poželjnosti $C_i(\cdot, \cdot), i \in 0, \dots, L-1$,
2. niz koeficijenata izgladivanja $(\varrho_t)_{t \geq 1}$ uz $\varrho_t \in (0, 1)$,
3. veličina uzorka N i veličina poduzorka N_b te
4. početna distribucija $p_0 \in \mathbb{P}(\mathbb{A})^L$.

3.2.1. Početak

Za $t = 0$ se postavlja $p = p_0$. Iterirati kroz korake $t = 1, 2, \dots$ sve dok uvjet zaustavljanja nije zadovoljen.

3.2.2. Uzorkovanje

Uzorkovanje (engl. *sampling*) je postupak izgradnje skupa rješenja na temelju trenutne distribucije. Ako je trenutna distribucija $p \in \mathbb{P}(\mathbb{A})^L$, tada je vjerojatnost uzorkovanja rješenja $s = (s_1, \dots, s_L) \in S$ dana izrazom:

$$Q_p(s) := Q_p(s_1; 1, \diamond) \cdot \prod_{i=2}^L Q_p(s_i; i, (s_1, \dots, s_{i-1}))$$

pri čemu je:

$$Q_p(a; i, y) := \frac{p(a, i)C_{i-1}(y, a)}{\sum_{a' \in \mathbb{A}} p(a', i)C_{i-1}(y, a')}$$

vjerojatnost da se izvodljivi simbol $a \in \mathbb{A}$ nadoda na poziciju i izvodljivog parcijalnog rješenja $y \in R_{i-1}$. Koristi se konvencija $\frac{0}{0} = 0$. Na ovakav način, algoritam uzorkuje N rješenja $s^{(1)}, \dots, s^{(N)}$ neovisno i podjednako distribuirano.

3.2.3. Ocjenjivanje

Ocjenjivanje (engl. *evaluation*) je postupak vrednovanja skupa rješenja dobivenih uzorkovanjem na temelju funkcije kazne. Neka su uzorci $x := (s^{(1)}, \dots, s^{(N)})$ poređani prema funkciji kazne f :

$$f(s^{n_1}) \leq f(s^{n_2}) \leq \dots \leq f(s^{n_N})$$

te neka je odabrano najboljih N_b uzoraka $N_b := \{s^{(n_1)}, s^{(n_2)}, \dots, s^{(n_{N_b})}\}$. Nakon toga, relativna frekvencija simbola a na poziciji $i \in 1, \dots, L$ u odabranom djelu uzorka se određuje izrazom:

$$w(a; i, x) := \frac{1}{N_b} \sum_{s \in N_b} \mathbb{1}_{\{a\}}(s_i)$$

i prikuplja se frekvencija za svaki $a \in \mathbb{A}$ te se kreira $w(i, x) = w(a; i, x)_{a \in \mathbb{A}}$ i

$$w(x) := (w(1, x), \dots, w(L, x)).$$

Tada je $w(x)$ distribucija vjerojatnosti nad $\mathbb{P}(\mathbb{A})^L$ koja daje relativne frekvencije simbola iz boljeg dijela uzorka x uzorkovanog s vjerojatnosti Q_p .

3.2.4. Ažuriranje

Nakon što je skup rješenja uzorkovan i ocijenjen, potrebno je trenutnu distribuciju ažurirati (engl. *update*). Trenutnu distribuciju p ažuriramo kao linearnu interpolaciju p i relativne frekvencije $w(x)$ uz parametar ϱ_{t+1} prema izrazu:

$$p := (1 - \varrho_{t+1})p + \varrho_{t+1}w(x)$$

U idućem koraku se brojač t uvećava za 1 i korak uzorkovanja se obavlja s novom distribucijom p .

4. Primjena na problem vodećih jedinica

Kako bi se bolje prikazalo ponašanje konstruktivnog optimizacijskog algoritma, u nastavku je razmatrana primjena algoritma na problem vodeće jedinice (engl. *LeadingOne*). Problem se sastoji od generiranja niza nula i jedinica s ciljem maksimiziranja broja početnih jedinica. Optimalno rješenje je ono u kojem se niz sastoji isključivo od jedinica. Prateći notaciju iz prethodnih poglavlja, problem se može formalizirati tako da je abeceda znakova $\mathbb{A} = \{0, 1\}$, skup svih rješenja $S = \{0, 1\}^L$ te funkcija kazne:

$$f(s) := L - \sum_{l=1}^L \prod_{i=1}^l s_i, \text{ za } s = (s_1, \dots, s_L)$$

Minimiziranjem kazne, broj početnih uzastopnih jedinica se maksimizira. Definirajmo dodatno τ kao prvu iteraciju u kojoj se pronalazi optimalno rješenje:

$$\tau := \min\{t \geq 0 | X_t \cap S^* \neq \emptyset\}$$

pri čemu je $X_t := \{X_t^{(1)}, \dots, X_t^{(N)}\}$ skup svih rješenja uzorkovanih u iteraciji t .

U poglavlju 3, teoremu 2 rada Wu i Kolonko (2014) se tvrdi da uz odabir konstantnog parametra izgladivanja $\varrho_t = \varrho$, veličine uzorka $N = L^{(2+\epsilon)}$, uz $\epsilon > 0$ i $N_b = \lfloor (\beta N) \rfloor$ za $0 < \beta < \frac{1}{3e} \prod_{m=1}^{\infty} (1 - (1 - \varrho)^m)$. Uz početnu distribuciju $\prod_0(1, i) \equiv \frac{1}{2}$, odnosno jednoliku distribuciju, za prethodno definirani problem vodeće jedinice vrijedi $\mathbb{P}(\tau < L) \rightarrow 1$ kada $L \rightarrow \infty$.

Ovaj teorem je eksperimentalno vrednovan, a rezultati su prikazani u tablici 4.1. Za svaku testiranu duljinu rješenja, broj iteracija potrebnih da rješenje konvergira u 1 je manji od L . Prema dobivenim rezultatima se naslućuje da bi daljnjim rastom duljine L teorem i dalje bio zadovoljen.

Utjecaj parametra izgladivanja prikazan je u tablici 4.2. Iz mjerenja je vidljivo da opisani problem povećanjem parametra izgladivanja brže konvergira željenom rješenju. Najbolji rezultat je dobiven uz $\varrho_t = \varrho = 1$ što predstavlja slučaj u kojem

Tablica 4.1: Utjecaj duljine uzorka L na broj iteracija ($\epsilon = 0.5, \beta = 0.09$)

L	N	N_b	ϱ	i
10	316	28	0.8	6
20	1788	160	0.8	9
30	4929	443	0.8	13
40	10119	910	0.8	16
50	17677	1590	0.8	20
60	27885	2509	0.8	23
70	40996	3689	0.8	26
80	57243	5151	0.8	30
90	76843	6915	0.8	33
100	100000	9000	0.8	37

trenutnu distribuciju p zamjenjujemo relativnom frekvencijom uzorkovanja, odnosno $p := w(x)$.

Tablica 4.2: Utjecaj parametra izgladivanja ϱ_t na broj iteracija ($\epsilon = 0.5, \beta = 0.09$)

L	N	N_b	ϱ	i
50	17677	6	0.2	43
50	17677	82	0.3	33
50	17677	279	0.4	29
50	17677	563	0.5	25
50	17677	881	0.6	23
50	17677	1195	0.7	21
50	17677	1483	0.8	19
50	17677	1736	0.9	18
50	17677	1950	1.0	15

Za svaki testirani skup parametara vršeno je 30 testova, a u tablicama je naveden medijan dobivenih vrijednosti. U svim navedenim testovima uvjet zaustavljanja je bio da vjerojatnost p da se na poziciji i uzorkuje 1 bude veća od 0.999:

$$p(1, i) > 0.999, \text{ za svaki } i \in \{0, \dots, L - 1\}.$$

5. Primjena na problem izrade rasporeda laboratorijskih vježbi

Izrada rasporeda laboratorijskih vježbi je specijalizacija problema raspoređivanja. Cilj je svakom studentu pridružiti termin laboratorijskih vježbi s kojim on nema kolizije, a da pritom niti jedan termin ne bude niti prepunjen niti podpunjen. Glavna razlika izrade rasporeda laboratorijskih vježbi u odnosu na izradu rasporeda ispita je ta što laboratorijsku vježbu treba smjestiti u postojeći raspored studenata, dok se prilikom izrade rasporeda ispita pretpostavlja da za vrijeme ispita studenti nemaju predavanja. Također, raspoređivanje za laboratorijske vježbe se vrši za svaki predmet neovisno, dok se prilikom izrade rasporeda ispita uzimaju svi ispiti studenta u obzir. Dodatno, prilikom izrade rasporeda laboratorijskih vježbi termini u kojima se laboratorijske vježbe mogu održati su unaprijed određene, dok se prilikom izrade rasporeda ispita trebaju odrediti i termini. Tvrdi ograničenja izrade rasporeda laboratorijskih vježbi su:

- svakom studentu treba dodijeliti termin laboratorijske vježbe,
- student ne smije imati koliziju s dodijeljenim terminom laboratorijske vježbe,
- u termin ne smije biti smješteno više od maksimalnog broja studenata za termin
- u termin ne smije biti smješteno manje od minimalnog broja studenata za termin.

Nakon što su navedena tvrda ograničenja zadovoljena, raspoređivanje se dodatno vrednuje mekim ograničenjima. Meka ograničenja dodatno kažnjavaju rasporede u kojima:

- je termin pridijeljen studentu na dan na koji nema predavanja i
- termin produžuje ukupno vrijeme studenta na fakultetu (laboratorijska vježba nije u rupi između drugih predavanja).

5.1. Formalna definicija problema

Konkretni problem raspoređivanja obrađen u ovom radu se odnosi na izradu rasporeda za laboratorijske vježbe iz predmeta Digitalna logika i Objektno orijentirano programiranje. Prema notaciji iz 3, skup abecede \mathbb{A} je skup *Termini* svih termina laboratorijskih vježbi. Duljina uzorka L je broj studenata u skupu *Studenti* koje treba rasporediti. U distribuciji p , vrijednost na mjestu p_{ij} predstavlja vjerojatnost da studentu j bude pridijeljen termin i . Rješenje problema je niz $s = (s_1, \dots, s_L)$ pri čemu je s_1 termin laboratorijske vježbe za prvog studenta itd. Nad svakim studentom iz skupa *Studenti* je definirana metoda $imaKolizijuS(Termin) = \{\top, \perp\}$ koja vraća \top ako student ima koliziju s predanim terminom, odnosno \perp kada student nema koliziju s predanim terminom. Metoda $produljujeTrajanjeDana(Termin) = \{\top, \perp\}$ definirana nad elementima skupa *Studenti* vraća \top ako bi pridjeljivanje termina studentu produžilo trajanje dana na fakultetu, a \perp ako ne bi. Odnosno, ova metoda vraća \top kada predani termin nije u rupi između drugih predavanja studentu, a \perp kada je. $naSlobodanDan(Termin) = \{\top, \perp\}$ je metoda definirana nad elementima skupa *Studenti* koja vraća \top ako je predani termin studentu u danu u kojem nema niti jedno predavanje, a \perp ako student na dan termina ima predavanja.

5.2. Inicijalna distribucija

U problemu vodećih jedinica inicijalna distribucija je uniforma kako bi se demonstrirao rad algoritma. U stvarnom problemu kao što je problem izrade rasporeda uniformna početna distribucija može uvelike odužiti vrijeme potrebno da algoritam konvergira prema rješenju. Zato je korisno inicijalizirati početnu distribuciju u skladu s domenom problema kako bi se algoritam usmjerio prema rješenju. Kod problema raspoređivanja termina laboratorijskih vježbi studentima, u samom početku (prije početka rada algoritma) moguće je predvidjeti da će određena pridruživanja termina studentima biti nepovoljnija od drugih. U konačnom rješenju nije dopušteno da student ima koliziju s pridruženim terminom, stoga je jasno da u inicijalnoj distribuciji treba studentu pridružiti malu vjerojatnost da mu se pridruži termin s kojim ima koliziju. Također, poznato je da ako termin produljuje trajanje dana studentu ili je na studentov slobodan dan, da će to rješenje biti nepovoljnije od onih koja ne produljuju trajanje dana studentu. Pseudokod inicijalizacije početne distribucije koja je u skladu s prethodnim opažanjima prikazan je na 2. Pridruživanje vjerojatnosti se vrši na način da se svakom studentu za svaki termin pridijeli određena vrijednost proporcionalna tomu koliko je taj termin

povoljan za studenta. Nakon što su studentu tako pridružene vjerojatnosti potrebno je normalizirati dobivenu raspodjelu.

5.3. Funkcija dodjeljivanja kazne

Funkcija dodjeljivanja kazne dodjeljuje kaznu svakom pridruživanju studenata i termina. Ulaz u funkciju je lista pridruživanja studenata i termina. Ulazna lista je veličine broja studenata, a svaki element liste predstavlja indeks termina koji je pridijeljen studentu na odabranom indeksu liste. Na primjer, neka je potrebno rasporediti pet studenata na tri termina laboratorijskih vježbi. Jedan od načina pridruživanja je:

$$[2, 2, 0, 1, 0].$$

Ovakvo pridruživanje označava da su $Student_0$ i $Student_1$ raspoređeni na $Termin_2$, $Student_2$ i $Student_4$ na $Termin_0$, a $Student_3$ na $Termin_1$. Izlaz iz funkcije je broj koji označava kaznu za predano rješenje.

Prilikom dodjeljivanja kazne uzeta su u obzir tvrda i meka ograničenja navedena na početku poglavlja. Kako bi bilo osigurano da algoritam svakako zadovolji tvrda ograničenja, a da na temelju mekih samo fino podešava (engl. *fine tuning*), kazna koja se dodjeljuje za kršenje tvrdih ograničenja je dva reda veličina veća od kazne za kršenje mekih ograničenja. Kažnjavanje za prepunjavanje termina laboratorijskih vježbi se dodjeljuje kvadratno. Time je postignuto da algoritam ravnomjernije raspoređuje studente jer je kazna znatno manja ako su četiri termina prepunjena s po jednim studentom, nego ako je jedan termin prepunjen s 4 studenta. Pseudokod funkcije s konkretnim vrijednostima kazni je prikazan na 3.

5.4. Heuristike

Kako je problem izrade rasporeda daleko složeniji od problema vodećih jedinica, u algoritam je dodano nekoliko nadogradnji kako bi algoritam uspješno rješavao problem izrade rasporeda. Jedna od nadogradnji je dodavanje heuristika kojima bi se nakon ažuriranja trenutne distribucije relativnom frekvencijom uzorkovanja, ta distribucija još dodatno poboljšala. Ideja počiva na tome da algoritam prilikom svoga rada rješenja vrednuje isključivo na temelju vrijednosti koje rješenju dodjeli funkcija kazne, a pritom ne zna ništa o domeni problema niti konkretnim razlozima zbog kojeg je rješenje dobilo dodijeljenu kaznu. Heuristikama se nastoji modificirati trenutnu distribuciju na temelju spoznaja o konkretnom problemu.

Algorithm 2 Izračun inicijalne distribucije

```
inicijalneVrijednosti  $\leftarrow$  []
 $n \leftarrow \text{duljina}(\text{Termini})$ 
 $m \leftarrow \text{duljina}(\text{Studenti})$ 
for ( $i \leftarrow 0; i < n; i \leftarrow i + 1$ ) do
  for ( $j \leftarrow 0; j < m; j \leftarrow j + 1$ ) do
    inicijalneVrijednosti[ $\text{Termin}_i$ ][ $\text{Student}_j$ ]  $\leftarrow$  10
    if  $\text{Student}_j.\text{imaKolizijuS}(\text{Termin}_i)$  then
      inicijalneVrijednosti[ $\text{Termin}_i$ ][ $\text{Student}_j$ ]  $\leftarrow$ 
      inicijalneVrijednosti[ $\text{Termin}_i$ ][ $\text{Student}_j$ ] - 8
    end if
    if  $\text{Student}_j.\text{produljujeTrajanjeDana}(\text{Termin}_i)$  then
      inicijalneVrijednosti[ $\text{Termin}_i$ ][ $\text{Student}_j$ ]  $\leftarrow$ 
      inicijalneVrijednosti[ $\text{Termin}_i$ ][ $\text{Student}_j$ ] - 1
    end if
    if  $\text{Student}_j.\text{naSlobodanDan}(\text{Termin}_i)$  then
      inicijalneVrijednosti[ $\text{Termin}_i$ ][ $\text{Student}_j$ ]  $\leftarrow$ 
      inicijalneVrijednosti[ $\text{Termin}_i$ ][ $\text{Student}_j$ ] - 1
    end if
  end for
end for
sumaStupaca  $\leftarrow$  []
for ( $i \leftarrow 0; i < n; i \leftarrow i + 1$ ) do
  for ( $j \leftarrow 0; j < m; j \leftarrow j + 1$ ) do
    sumaStupaca[ $\text{Student}_j$ ]  $\leftarrow$  sumaStupaca[ $\text{Student}_j$ ] +
    inicijalneVrijednosti[ $\text{Termin}_i$ ][ $\text{Student}_j$ ]
  end for
end for
for ( $i \leftarrow 0; i < n; i \leftarrow i + 1$ ) do
  for ( $j \leftarrow 0; j < m; j \leftarrow j + 1$ ) do
    distribucija[ $\text{Termin}_i$ ][ $\text{Student}_j$ ]  $\leftarrow$  inicijalneVrijednosti[ $\text{Termin}_i$ ][ $\text{Student}_j$ ] / sumaStupaca[ $\text{Student}_j$ ]
  end for
end for
```

Algorithm 3 Funkcija dodjeljivanja kazne

Ulaz: *uzorak* – uzorak jednog rješenja.

Izlaz: kazna za predano rješenje.

$kazna \leftarrow 0$

$popunjenost \leftarrow []$

$n \leftarrow \text{duljina}(\text{Studenti})$

for ($i \leftarrow 0; i < n; i \leftarrow i + 1$) **do**

if $\text{Student}_i.\text{imaKolizijuS}(\text{uzorak}_i)$ **then**

$kazna \leftarrow kazna + 80000$

end if

if $\text{Student}_i.\text{produljujeTrajanjeDana}(\text{uzorak}_i)$ **then**

$kazna \leftarrow kazna + 50$

end if

if $\text{Student}_i.\text{naSlobodanDan}(\text{uzorak}_i)$ **then**

$kazna \leftarrow kazna + 50$

end if

$popunjenost[\text{uzorak}_i] \leftarrow popunjenost[\text{uzorak}_i] + 1$

end for

$n \leftarrow \text{duljina}(\text{Termini})$

for ($i \rightarrow 0; i < n; i \rightarrow i + 1$) **do**

if $popunjenost[\text{uzorak}_i] > \text{Termin}_i.\text{maksimalanBrojStudenata}()$ **then**

$kazna \leftarrow kazna + 5000 + \text{koefficient_prepunjenja} \cdot$
 $(popunjenost[\text{uzorak}_i] - \text{Termin}_i.\text{maksimalanBrojStudenata}())^2$

end if

if $popunjenost[\text{uzorak}_i] < \text{termin}_i.\text{minimalanBrojStudenata}()$ **then**

$kazna \leftarrow kazna + 5000 + \text{koefficient_prepunjenja} \cdot$
 $(\text{Termin}_i.\text{minimalanBrojStudenata}() - popunjenost[\text{uzorak}_i])^2$

end if

end for

return $kazna$

5.4.1. Rebalansiranje trenutne distribucije

Kako je u problemu izrade rasporeda laboratorijskih vježbi broj studenata velik, a broj termina u kojima su prostorije za izvršavanje laboratorijskih vježbi slobodne znatno manji, čest je slučaj da se u jednom vremenskom terminu održavaju vježbe u dvije različite prostorije. U tim situacijama studentu oba termina jednako odgovaraju (jer je jedina razlika prostorija u kojoj će laboratorijska vježba biti održana). Iako se iz perspektive studenta dva istovremena termina ne razlikuju, algoritam bez heuristike ih smatra potpuno različitim. Zbog toga se može dogoditi da algoritam prepunjuje jedan termin, dok drugi termin u isto vrijeme može biti podpunjen.

Dodavanje heuristike koja ravnomjerno rebalansira vjerojatnosti između svih istovremenih termina je implementacijski jednostavna, a donosi poboljšanje u radu algoritma. Pseudokod 4 prikazuje opisanu heuristiku. *IstovremeniTermini* je mapa kojoj su ključevi termini, a vrijednosti su liste svih istovremenih termina (uključujući i sam termin koji je ključ). Na ovaj način se jednostavno može doći do lista svih istovremenih termina (to su sve vrijednosti u mapi *IstovremeniTermini*). Izgradnja ovakve mape u programskom jeziku Java prikazano je u 5.1.

Algorithm 4 Heuristika rebalansiranja istovremenih termina

```
ListeIstovremenihTermina  $\leftarrow$  IstovremeniTermini.vrijednosti()
n  $\leftarrow$  duljina(Studenti)
for (i  $\leftarrow$  0; i < n; i  $\leftarrow$  i + 1) do
    for (ListaIstovremenihTermina : ListeIstovremenihTermina) do
        suma  $\leftarrow$  0
        for (Termin : ListaIstovremenihTermina) do
            suma  $\leftarrow$  suma + TrenutnaDistribucija[Termin][Studenti]
        end for
        balansirano  $\leftarrow$  suma/duljina(ListaIstovremenihTermina)
        for (Termin : ListaIstovremenihTermina) do
            TrenutnaDistribucija[Termin][Studenti]  $\leftarrow$  balansirano
        end for
    end for
end for
```

Listing 5.1: Izrada mape istovremenih termina u programskom jeziku Java

```
SimpleDateFormat timeFormat = new
    SimpleDateFormat("yyyy-MM-dd HH:mm");
```



```

for (int i=0, n=labs.size(); i<n; ++i) {
    String labTime =
        timeFormat.format(labs.get(i).getTime().getStart());

    if (!labsAtTime.containsKey(labTime)) {
        labsAtTime.put(labTime, new ArrayList<>());
    }

    labsAtTime.get(labTime).add(i);
}

```

5.4.2. Redistribucija vjerojatnosti prepunjenih termina

Kao što je prethodno navedeno, algoritam ne zna na temelju čega se pojedinom rješenju dodjeljuje kazna. Zato je korisno dodati heuristiku koja će znati na temelju čega su dodijeljene kazne i djelovati u smjeru da ublaži buduće dodjeljivanje kazni. Kako se kvalitetnom inicijalnom distribucijom može jako dobro riješiti problem stvaranja kolizija, algoritmu je dodana heuristika koja rješava problem prepunjavanja.

Ideja heuristike je da onim terminima koji su prepunjeni smanji vjerojatnost odabiranja prilikom idućeg uzorkovanja. Kako zbroj vjerojatnosti mora uvijek biti jednak jedan, potrebno je preostalim terminima koji nisu prepunjeni povećati vjerojatnost odabiranja. Za koliko će se smanjiti vjerojatnost odabiranja pojedinom terminu se određuje tako da se svi prepunjeni termini proporcionalno rasporede na zadani interval. Time se postiže da se terminima koji su bili prepunjeni u više uzoraka vjerojatnost odabiranja smanji intenzivnije nego onim terminima koji su bili prepunjeni u manjem broju uzoraka. Implementacija heuristike je prikazana u isječku koda 5.2. Varijabla *overFilledLabs* je mapa koja kao ključeve ima indekse prepunjenih termina, a vrijednosti su broj uzoraka u kojima je odgovarajući termin bio prepunjen. U početku rada algoritma su sva generirana rješenja loša i mnogo je termina prepunjeno te se eksperimentalno pokazalo da je ovu heuristiku korisno početi koristiti u kasnijim fazama rada algoritma.

Listing 5.2: Redistribucija vjerojatnosti prepunjenih termina

```

double UPPER_BOUND = 0.05;
double LOWER_BOUND = 0.01;
int maxi = overFilledLabs.values()

```

```

        .stream()
        .mapToInt(Integer::intValue)
        .max()
        .getAsInt();

for (int j = 0, m = students.size(); j < m; ++j) {
    double redistribute = 0;

    for (Map.Entry<Integer, Integer> overfiled :
        overFilledLabs.entrySet()) {
        double reduceCoff = (((double)
            overfiled.getValue()) / maxi) * (UPPER_BOUND -
            LOWER_BOUND) + LOWER_BOUND;

        redistribute +=
            currentDistribution[overfiled.getKey()][j] *
            reduceCoff;
        currentDistribution[overfiled.getKey()][j] *= (1 -
            reduceCoff);
    }
    double increment = redistribute / (labs.size() -
        overFilledLabs.size());
    for (int i = 0, n = labs.size(); i < n; ++i) {
        if (overFilledLabs.containsKey(i)) continue;
        currentDistribution[i][j] += increment;
    }
}
}

```

5.5. Nadogradnje algoritma prioritetnim redom

U originalnom algoritmu opisanom u Wu i Kolonko (2014) trenutna distribucija se ažurira isključivo vjerojatnostima dobivenim relativnim uzorkovanjem najboljih uzoraka. Takav pristup je uspješan na problemima poput problema vodeće jedinice gdje je velika sličnost između distribucija koje su generirale rješenje s jednakom kaznom. Na primjer, ako dvije distribucije generiraju uzorke s početnih deset jedinica uzas-

topno, velika je vjerojatnost da će obje distribucije na prvih deset mjesta imati puno veću vjerojatnost za generiranje jedinice, nego za generiranje nule. Zbog toga sva dobra rješenja usmjeruju distribuciju u istom smjeru, smjeru u kojem su vjerojatnosti za generiranje jedinice na svim mjestima veće nego za generiranje nule. Kod problema izrade rasporeda laboratorijskih vježbi to nije slučaj. Dvije distribucije mogu konzistentno generirati rješenja koja će imati isti iznos kazne, a da pritom distribucije budu vrlo različite. Tomu je tako jer kod izrade rasporeda postoji puno više rješenja koja su jednako dobra. Jednako su dobra jer prema funkciji kazne prikazanoj na 3 se u slučaju kada je studentu dodijeljen termin koji mu je unutar rupe u predavanjima sporedno koji je to od termina. Dokle god je termin laboratorijske vježbe u rupi između predavanja, studentu je podjednako dobro u koji je termin raspoređen. Originalni algoritam se ne koristi ovom činjenicom, nego ima tendenciju da kada pronađe dobar termin za studenta da ga nastoji držati u tom terminu, a možda je povoljnije prebaciti studenta u neki termin koji mu jednako odgovara i drugog studenta staviti na njegovo mjesto.

Kako bi se povećala raznovrsnost rješenja koje algoritam uzima u obzir, algoritam je nadopunjen s prioriternim redom koji pamti određen broj najboljih viđenih rješenja. Potom se prilikom ažuriranja distribucije uz relativnu frekvenciju novih uzoraka u obzir uzimaju i uzorci iz prioriternog reda. U kolikoj mjeri će se uzorci iz prioriternog reda uzeti u obzir prilikom ažuriranja trenutne distribucije određeno je koeficijentom prioriternog reda. Kako je red fiksne duljine, jednom kada dosegne svoju maksimalnu veličinu, novi element se ubacuje tek ako je bolji od najgoreg rješenja u redu, a najgore rješenje u redu se izbacuje. Baš zbog prethodno navedene potrebe da se često pristupa elementu s najvećom kaznom je odabrana struktura prioriternog reda. Dodavanjem prioriternog reda povećava se količina dobrih rješenja koja algoritam uzima u obzir prilikom ažuriranja trenutne distribucije. Da bi se spriječilo da red usporava napredak algoritma zadržavajući ga u lokalnim optimumima, red se periodički potpuno isprazni.

5.6. Rad algoritma

Osim prethodno navedenih nadogradnja, sama srž algoritma je ostala ista kao i u Wu i Kolonko (2014). Nakon što se inicijalizira početna distribucija započinje petlja u kojoj se uzorkuju novi uzorci, zatim se oni ocjenjuju te se gradi distribucija relativnih frekvencija uzoraka s najmanjom kaznom. Nakon što se trenutna distribucija ažurira, provode se heuristike opisane u poglavlju 5.4. Pseudokod ovog algoritma je prikazan na 5. Algoritam nastavlja s radom sve dok se ne ispuni uvjet zaustavljanja. Uvjeti zaustavljanja mogu biti različiti. Jedan od načina da se zaustavi algoritam je da se u

vršnom direktoriju projekta stvori datoteka s imenom *stop.txt*. Ovakav uvjet zaustavljanja je praktičan kada postoji potreba da se prati kako algoritam napreduje te da ga se prekine jednom kada dosegne željenu kvalitetu rasporeda. Ovaj pristup je korišten za vrijeme razvijanja te bi bio pogodan za korištenje u produkcijskom okruženju. Za potrebe automatskog vrednovanja je prikladnije algoritam zaustaviti nakon određenog broja iteracija ili nakon što iznos kazne najboljeg rješenja dosegne zadanu vrijednost.

Algorithm 5 Rad algoritma

repeat

uzorci \leftarrow *uzorkovanje*()

relativnaFrekvencija \leftarrow *ocjenjivanje*(*uzorci*)

azuriranje(*relativnaFrekvencija*)

pokreniHeuristike()

until *uvjetZaustavljanja*()

6. Vrednovanje algoritma

U ovom poglavlju prikazani su rezultati rada algoritma na problemu izrade rasporeda za laboratorijske vježbe iz kolegija Digitalna logika i Objektivno orijentirano programiranje. Kolegiji su održani u akademskoj godini 2018./ 2019. na Fakultetu elektrotehnike i računarstva.

6.1. Razvoj algoritma

Početni algoritam je bio identičan onome koji je korišten za rješavanje problema vođenih jedinica. Duljina niza je bila predstavljena brojem studenata, a skup abecede \mathbb{A} terminima laboratorijskih vježbi. Algoritam u takvom obliku nije uspješno rješavao probleme raspoređivanja koji su korišteni u ovome radu (nije uspijevaio zadovoljiti tvrda ograničenja). Prvi korak u poboljšanju algoritma je bila definicija dobre inicijalne distribucije kao što je opisano u poglavlju 5.2. Dodavanjem inicijalne distribucije algoritam je počeo zadovoljavati tvrda ograničenja algoritma. U želji za što boljim zadovoljavanjem mekih ograničenja algoritam je nadograđen prioritarnim redom. Rad prioritarnog reda je opisan u poglavlju 5.5. Uvođenje prioritarnog reda je doprinijelo uspješnijem zadovoljavanju mekih ograničenja. Analizom konkretnih problema raspoređivanja za zadane laboratorijske vježbe, uočeno je da postoje termini laboratorijskih vježbi koji se odvijaju istovremeno, ali u različitim prostorijama. Zbog takvih termina je uvedena heuristika opisana u poglavlju 5.4.1. Opisana distribucija pomaže u slučajevima kada algoritam prepunjuje jedan termin, a postoji termin u isto vrijeme (i jednako dobar studentu) u kojem ima mjesta. Zadnji pokušaj unaprjeđenja algoritma je dodavanje heuristike za redistribuciju vjerojatnosti prepunjenih termina. Sama ideja redistribucije je opisana u poglavlju 5.4.2. Redistribucija vjerojatnosti ne djeluje dobro u samom početku rada algoritma jer su sva rješenja loša i ima mnogo prepunjenih termina. Stoga redistribuciju valja početi koristiti u kasnijim fazama rada algoritma. Dodatno, treba odrediti za koliko će se smanjiti vjerojatnost svakog prepunjenog termina. U okviru ovog rada nije uspješno utvrđeno u kojem trenutku treba početi koristiti

Tablica 6.1: Razvoj algoritma - horizont

Inicijalna dist.	Prior. red	Rebalansiranje	Redistribuiranje	Prepunjenost	Kolizije	Medijan	Srednja vrijednost	Najmanji	Najveći
⊥	⊥	⊥	⊥	0	2	346000	425990	346000	676700
T	⊥	⊥	⊥	0	0	20400	20315	20050	20950
T	T	⊥	⊥	0	0	19350	19265	18250	20650
T	T	T	⊥	0	0	21250	24250	21250	36250
T	T	T	T	1	0	50800	49295	35550	51000

redistribuciju i za koliko treba smanjiti vjerojatnosti prepunjenih termina. Pokušaj koji je davao najbolje rezultate je opisan u navedenom poglavlju, ali taj postupak još uvijek nije poboljšavao rad algoritma.

Kako se kretala vrijednost funkcije kazne u ovisnosti o nadogradnjama algoritma prikazano je u tablici 6.1. Vrijednosti prikazane u tablici dobivene su na temelju deset testova. Iako se promatranjem tablice doima kako heuristika rebalansiranja odmaže radu algoritma, to je samo posljedica što je izvršen malen broj testova. Kako ta heuristika isključivo rebalansira vjerojatnosti između istovremenih termina, ona ne može naštetiti radu algoritma. Ekvivalent uvođenju ove heuristike bi bilo dodatno obrađivanje termina laboratorijskih vježbi na način da se istovremeni termini spoje u jedan virtualni termin (čiji bi kapacitet bio jednak zbroju svih istovremenih termina) te da se u radu algoritma koristi taj jedan virtualni termin. Na kraju rada algoritma bi bilo dodatno potrebno sve studente raspoređene u virtualni termin, rasporediti u stvarne, istovremene termine.

6.2. Utjecaj parametara na rad algoritma

U ovom poglavlju prikazan je utjecaj parametara algoritma na rad završnog algoritma. Na temelju zaključaka iz prethodnog poglavlja, osnovni algoritam je nadograđen inicijalnom distribucijom, heuristikom rebalansiranja te prioritarnim redom. Sva mjerenja u narednim potpoglavljima načinjena su nad tako modificiranim algoritmom. Za svaki skup parametara je vršeno 30 testova, a svaki test je zaustavljen nakon 3000 iteracija. Svi testovi su vršeni nad problemom *Problem6* (detaljan opis svakog problema je dan u poglavlju 6.3). U svim tablicama ovog poglavlja, stupac *Kolizije* predstavlja broj kolizija kod rješenja čija je vrijednost kazne bila medijan svih vrijednosti kazne. Jednako tako, stupac *Prepunjenost* predstavlja broj prepunjenih termina kod rješenja čija je vrijednost kazne bila medijan.

Tablica 6.2: Utjecaj L na rad algoritma

L	Prepunjenost	Kolizije	Medijan	Srednja vrijednost	Najmanji	Najveći
100	0	0	21820	21815	20800	25850
150	0	0	21800	22485	20950	36000
200	0	0	21600	23080	21550	36600
250	0	0	21200	21500	21000	28300
300	0	0	21150	21690	21050	36450

6.2.1. Veličina uzorka

Prikaz utjecaja veličine uzorka L na rad algoritma prikazan je u tablici 6.2. U svim primjerima je podskup najboljih rješenja na temelju kojih se gradi relativna frekvencija bio $N_b = 50$, parametar zaglađivanja $\varrho = 0.5$, veličina prioritetnog reda je bila 50, koeficijent prioritetnog reda 0.3 te koeficijent prepunjenja *koeficijent_prepunjenja* = 10000. Može se zaključiti da se povećanjem veličine uzorka dobivaju kvalitetniji rasporedi. Također je zanimljivo uočiti da je najmanja razlika između maksimalne i minimalne kazne u slučaju kada je selekcijski pritisak najmanji. Valja uočiti da algoritam zadovoljava tvrda ograničenja sa svakim skupom parametara, odnosno da veličina uzorka L utječe samo na meka ograničenja.

6.2.2. Koeficijent prepunjenja

Koeficijentom prepunjenja se određuje koliko snažno će se kažnjavati prepunjenja. Prilikom svih mjerenja, kolizije su se kažnjavale s 80000. Ono što se vjerojatno prvo zapazi pogledom na tablicu 6.3 jest da za koeficijente 15000, 20000, 25000 je maksimalna izmjerena kazna za jedan red veličine veća nego kod koeficijenta 5000 i 10000. To su slučajevi u kojima su u rješenjima postojale jedna ili više kolizija. Takva rješenja su nastala zato što je algoritam prestrogo kažnjavao prepunjenja, u odnosu na kolizije. Kako se zbog dobre inicijalne distribucije očekuje malen broj kolizija, svaku koliziju koja nastane potrebno je izrazito strogo kazniti kako algoritam ne bi krenuo u graditi rješenja u tom smjeru. Na taj način se suzbije šansa za nastankom kolizije, a potom je sasvim učinkovito prepunjavanja kažnjavati i manjim koeficijentom (jer u pravilu kolizije niti ne nastaju). Ovdje je bitno naglasiti da nije bitan apsolutan iznos koeficijenta prepunjenja, nego njegov relativan iznos u odnosu na kaznu za koliziju. Uz kaznu za koliziju od 80000, najbolji rezultati se ostvaruju uz koeficijent prepunjenja od 5000 jer u tom slučaju meka ograničenja imaju veći utjecaj. Povećanjem kazne za koliziju bi se

Tablica 6.3: Utjecaj koeficijenta prepunjenja na rad algoritma

Koef. prepunjenja	Prepunjenost	Kolizije	Medijan	Srednja vrijednost	Najmanji	Najveći
5000	0	0	20600	20603	20500	20700
10000	0	0	21150	21690	21050	36450
15000	0	0	21300	28621	21200	121350
20000	0	0	21550	35720	21550	261500
25000	0	0	21000	60620	20850	240950

Tablica 6.4: Utjecaj koeficijenta izgladivanja

Koef. izgladivanje	Prepunjenost	Kolizije	Medijan	Srednja vrijednost	Najmanji	Najveći
0.2	0	0	21300	21285	21200	21350
0.4	0	0	20800	20806	20800	20900
0.6	0	0	20600	20640	20600	20750

očekivalo da koeficijenti prepunjenja 5000, 10000 i dalje daju jednako dobre rezultate, dok bi se rezultati kod većih koeficijenata prepunjenja poboljšavali.

6.2.3. Koeficijent izgladivanja

Koeficijent izgladivanja ϱ označava u kolikoj mjeri će se pri računanju nove distribucije uzeti u obzir relativna frekvencija uzorkovanja. Valja napomenuti da na računanje nove distribucije djeluje i relativna frekvencija uzoraka iz prioritetnog reda koja je u svim testovima bila 0.3. Veličina prioritetnog reda je bila 50. Iz mjerenja u tablici 6.4 je vidljivo da veći koeficijent rezultira boljim rezultatima. Ono što je zanimljivo uočiti kod svih slučajeva je činjenica da je razlika između najveće i najmanje vrijednosti kazne vrlo mala. To znači da je za skup parametara algoritam u svih 30 testova konvergirao u skup vrlo sličnih rješenja.

6.2.4. Koeficijent prioritetnog reda

Utjecaj koeficijenta prioritetnog reda na rad algoritma je prikazan je u tablici 6.5. U svim primjerima je koeficijent izgladivanja bio $\varrho = 0.3$. U tablici je vidljivo da su bolji rezultati ostvareni s manjim koeficijentom prioritetnog reda. To se može objasniti kao posljedica da se povećanje koeficijenta prioritetnog reda dovodi do smanjenja utjecaja trenutne distribucije. Uz to, prioritetni red se svakih 50 iteracija prazni i potom puni ispočetka te stoga ne pamti cijelu povijest dobrih rješenja. Ovakvi rezultati su i

Tablica 6.5: Utjecaj koeficijenta prioritetnog reda

Koef. reda	Prepunjenost	Kolizije	Medijan	Srednja vrijednost	Najmanji	Najveći
0.2	0	0	20600	20588	20450	20750
0.4	0	0	21200	21208	21200	21250
0.6	0	0	21550	21565	21550	21600

Tablica 6.6: Utjecaj veličine prioritetnog reda

Koef. reda	Prepunjenost	Kolizije	Medijan	Srednja vrijednost	Najmanji	Najveći
10	1	0	36450	101406	36350	356350
20	0	0	21850	21845	21800	21850
30	0	0	21300	21783	21100	36450
50	0	0	21150	21690	21050	36450

očekivani jer prioritetni red nije uveden s razlogom da bi u većinskom djelu definirao trenutnu distribuciju, nego samo kako bi u manjim količinama pridonio raznovrsnosti dobrih rješenja.

6.2.5. Veličina prioritetnog reda

U tablici 6.6 je prikazan utjecaj veličine prioritetnog reda na rad algoritma. U svakom od primjera je koeficijent prioritetnog reda iznosio 0.3, a koeficijent izgladivanja 0.5. Može se primijetiti da uz prioritetni red veličine 10, rješenje čiji je iznos kazne bio medijan iznosa kazne svih rješenja, nije zadovoljio tvrda ograničenja problema. To je jedini primjer u ovome potpoglavlju koji nije uspio zadovoljiti tvrda ograničenja. Porastom veličine prioritetnog reda algoritam generira sve bolja rješenja. To se događa zbog sve veće raznovrsnosti dobrih rješenja koja omogućavaju algoritmu da uzme više dobrih rješenja u obzir prilikom ažuriranja distribucije.

6.3. Opis testnih primjera

Na Fakultetu elektrotehnike i računarstva sastavni dio mnogih kolegija su laboratorijske vježbe. Svaki od tih kolegija (u ovom radu su primjeri Digitalna logika i Objektno orijentirano programiranje) određuje tjedne u kojima se pojedina laboratorijska vježba treba održati. Svakom studentu treba pridijeliti termin laboratorijske vježbe unutar tjedna predviđenog za laboratorijske vježbe. Izrada rasporeda predavanja prethodi iz-

Tablica 6.7: Imenovanje problema

<i>Ime</i>	<i>Opis</i>
Problem 1	Laboratorijske vježbe iz Digitalne logike 2018./2019.
Problem 2	Laboratorijske vježbe iz Digitalne logike 2018./2019.
Problem 3	Laboratorijske vježbe iz Digitalne logike 2018./2019.
Problem 4	Laboratorijske vježbe iz Digitalne logike 2018./2019.
Problem 5	Laboratorijske vježbe iz Objektno orijentiranog programiranje 2018./ 2019.
Problem 6	Laboratorijske vježbe iz Objektno orijentiranog programiranje 2018./ 2019.

radi rasporeda laboratorijskih vježbi i pritom se ne razmatra koji tjedni su predviđeni za laboratorijske vježbe. Stoga se prilikom izrade rasporeda laboratorijskih vježbi dodjeljivanje termina laboratorijskih vježbi treba uklopiti u već određeni raspored predavanja studenata. Svi testni problemi korišteni u ovom radu su navedeni u tablici 6.7. Kako su studenti koji polaze kolegij Digitalna logika u većini bruceši koji slušaju isključivo kolegije s prve godine, njihovi rasporedi predavanja su kompaktni. Bruceši su većinom podijeljeni u jutarnje i popodnevne grupe te u skladu s time najčešće imaju sva predavanja u terminu od 8 do 13 ili 12 do 17. Dodatno, na kolegiju studenti mogu odabirati između izvođenje simulacijske i praktične inačice laboratorijskih vježbi. Raspored za svaku inačicu se određuje zasebno. Zbog toga je izrada rasporeda za Digitalnu logiku jednostavnija, no većina pridruženih termina produljuje trajanje dana na fakultetu studentima. S druge strane, kolegij Objektno orijentirano programiranje je kolegij koji se po FER2 programu održava na drugoj godini preddiplomskog studija. Zbog toga studenti koji slušaju taj kolegij često slušaju i neke kolegije s treće ili prve godine (i naravno druge godine). Uz to, predmet je obavezan za sve studente na smjeru Računarstvo te postoji samo jedna inačica vježbi. Zbog toga je broj studenata za rasporediti veći u odnosu na Digitalnu logiku te su rasporedi studenata puno manje kompaktni. Pojednosti o svakom problemu su prikazani u tablici 6.8. Treći i četvrti stupac tablice određuju maksimalan, odnosno minimalan broj studenata koji mogu biti raspoređeni u jedan termin. Maksimalan i minimalan broj studenata po terminu za navedene kolegije je jednak za sve termine.

6.4. Rezultati

U ovom poglavlju je predstavljen rezultat rada algoritma na svim problemima predstavljenim u tablici 6.7. Poglavlje je podijeljeno na dva potpoglavlja u kojem se prvo

Tablica 6.8: Podaci o problemima

<i>Broj</i>	<i>Problem1</i>	<i>Problem2</i>	<i>Problem3</i>	<i>Problem4</i>	<i>Problem5</i>	<i>Problem6</i>
Studenata	371	372	372	372	515	515
Termina	27	27	27	27	32	32
Maksimalno	14	14	14	14	19	19
Minimalno	0	0	0	0	17	17

potpoglavlje bavi rasporedom za laboratorijske vježbe iz kolegija Digitalna logika, a drugo kolegijem Objektno orijentirano programiranje. Za svaki od primjera je vršeno deset testova s po dva skupa parametara. Svaki test je zaustavljen nakon 3000 iteracija. Zbog jednostavnosti, skupovima parametara su dodjeljena imena kako je prikazano u tablici 6.9.

Glavna razlika između dva skupa parametara je u veličini uzorka koji se uzorkuje. Veličina uzorka koji se uzorkuje je izrazito bitna jer ona u velikoj mjeri određuje vrijeme koje je potrebno da se izvrši jedna iteracija algoritma. Vrijeme potrebno za jednu iteraciju algoritma je utvrđeno eksperimentom na računalu s Intel Core i7 procesorom na 2.5 GHz. Za $Parametri_{300}$ je potrebno 130ms za jednu iteraciju, dok je za $Parametri_{100}$ potrebno 45ms. Kao što je i očekivano, vrijeme potrebno za izvršavanje jedne iteracije algoritma sa skupom parametara $Parametri_{100}$ je približno tri puta manje od vremena potrebnog za izvršavanje jedne iteracije sa skupom parametara $Parametri_{300}$. Ova razlika se posebno očituje pri automatskom vrednovanju jer za izvršavanje deset testova po 3000 iteracija za skup parametara $Parametri_{100}$ je potrebno približno 23 minute, dok je za skup parametara $Parametri_{300}$ potrebno 65 minuta. U produkcijskom okruženju u kojem se algoritam najčešće pokreće manji broj puta vrijeme potrebno izradu jednog rasporeda sa skupom parametara $Parametri_{300}$ je manje od 7 minuta, a sa skupom parametara $Parametri_{100}$ manje od 3 minute. Ovdje je vidljivo da je uzorkovanje manjih uzoraka praktičnije za automatsko testiranje, dok u produkcijskom okruženju ovisno o konkretnim uvjetima izrada rasporeda se može vršiti i s većim brojem uzoraka koji se uzorkuju.

Kako je problem raspoređivanja uspješno riješen u svim primjerima (u svakom primjeru su zadovoljena tvrda ograničenja), u tablicama nisu prikazivani stupci s brojem kolizija i brojem prepunjenih termina. Broj kolizija i broj prepunjenih termina je nula za svaki primjer u nastavku. Zbog toga je u sljedećim potpoglavljima pažnja usmjerena na zadovoljavanje mekih ograničenja.

Tablica 6.9: Skupovi parametara

Ime skupa	N	N_b	ϱ	Duljina prior. reda	Koef. prior. reda	Koef. prepunjavanja
$Parametri_{300}$	300	50	0.6	50	0.3	10000
$Parametri_{100}$	100	50	0.5	50	0.2	7500

Tablica 6.10: Rezultati sa skupom parametara $Parametri_{300}$

Ime problema	Medijan	Srednja vrijednost	Najmanji	Najveći
$Problem1$	14900	14900	14850	15000
$Problem2$	15500	15480	15450	15500
$Problem3$	15600	15600	15600	15600
$Problem4$	15400	15410	15400	15450

6.4.1. Rezultati rasporeda za kolegij Digitalne logike

U tablici 6.10 su prikazani rezultati rada algoritma uz skup parametara $Parametri_{300}$, a u tablici 6.11 za skup parametara $Parametri_{100}$. Ponovnim proučavanjem pseudo-koda 3 i podataka o problemima 6.8 može se zaključiti da maksimalna kazna koju rješenje koje zadovoljava tvrda ograničenja može dobiti jest $100 \cdot 372 = 37200$. Tu kaznu bi dobilo rješenje koje je svakom studentu pridijelilo termin laboratorijske vježbe na dan u kojem student nema predavanje.

U rasporedu za $Problem1$ sa skupom parametara $Parametri_{300}$ medijan kazne je 14900. Kako su sva tvrda ograničenja zadovoljena, to znači da je kazna dobivena zbog produljenja trajanja dana studenata i pridjeljivanja termina na slobodan dan. Kako su kazne u oba slučaja 50, može se zaključiti da je kazna dodijeljena za maksimalno $14900/50 = 298$ pridruživanja (treba uzeti u obzir da ako je studentu pridružen termin na dan na koji nema predavanja, kazna za pridruživanje je 100 jer to pridruživanje ujedno i produljuje trajanje dana studentu). Prema podacima iz tablice 6.8 to znači da za minimalno $371 - 298 = 68$ pridruživanja nije pridijeljena nikakva kazna. S obzirom na opisan skup studenata koji pohađa kolegij opisan u tablici 6.3 činjenica da je algoritam uspio ne produžiti trajanje dana za 68 studenata je zadovoljavajuća.

Usporedno s time, algoritam sa skupom parametara $Parametri_{100}$ je za maksimalno 5 studenata pridijelio lošije termine nego što im je dodijelio algoritam sa skupom parametara $Parametri_{300}$. Uz jedno odstupanje, može se vidjeti da u svim primjerima algoritam uspijeva ne produžiti trajanje dana za od 55 do 68 studenata.

Tablica 6.11: Rezultati sa skupom parametara $Parametri_{100}$

Ime problema	Medijan	Srednja vrijednost	Najmanji	Najveći
<i>Problem1</i>	15150	16400	15150	27650
<i>Problem2</i>	27850	21600	15350	27850
<i>Problem3</i>	15850	15850	15850	15850
<i>Problem4</i>	15750	19500	15750	28250

Tablica 6.12: Rezultati sa skupom parametara $Parametri_{300}$

Ime problema	Medijan	Srednja vrijednost	Najmanji	Najveći
<i>Problem5</i>	21900	27895	21900	81850
<i>Problem6</i>	20950	20960	20950	21000

6.4.2. Rezultati rasporeda za kolegij Objektno orijentiranog programiranja

Skup studenata koji pohađa kolegij Objektno orijentiranog programiranja, kako je opisano u poglavlju 6.3, znatno je raznovrsniji od skupa studenata koji pohađaju kolegij Digitalne logike. Također, kod studenata na Objektno orijentiranom programiranju postoji puno više rupa u rasporedu u koje se potencijalno može ubaciti termin laboratorijske vježbe. S obzirom na navedeno, problemi *Problem5* i *Problem6* su znatno kompleksniji od ostalih problema, no nude i veće mogućnosti dobrog pridruživanja. Rezultati pridruživanja za spomenute probleme prikazani su u tablici 6.12 (sa skupom parametara $Parametri_{300}$) te u tablici 6.13 (sa skupom parametara $Parametri_{100}$). Kompleksnost ovih primjera se očituje u posljednjem stupcu obje tablice. Naime, u najgorem od deset testova, algoritam nije uspio zadovoljiti tvrda ograničenja za *Problem5* (uz $Parametri_{300}$) te za oba problema uz $Parametri_{100}$.

Računanje kolikom broju studenata nije produljeno trajanje dana je analogno onom u prethodnom potpoglavlju. Vidljivo je da ovdje algoritam uspijeva ne produžiti trajanje dana za od 96 do 106 studenata. S obzirom na to da na laboratorijske vježbe treba rasporediti 515 studenata dobiveni rezultat nije loš, ali svakako se studenti mogu rasporediti bolje.

Tablica 6.13: Rezultati sa skupom parametara $Parametri_{100}$

Ime problema	Medijan	Srednja vrijednost	Najmanji	Najveći
<i>Problem5</i>	20500	24250	20500	45500
<i>Problem6</i>	20450	24200	20450	45450

7. Zaključak

U sklopu ovog rada je implementiran konstruktivistički optimizacijski algoritam prikazan u Wu i Kolonko (2014). Implementacija je napravljena u programskom jeziku *Javi*. Eksperimentalno su potvrđeni teoremi navedeni u radu Wu i Kolonko (2014) koji se tiču učinkovitosti algoritma na problemu vodećih jedinica. Algoritam je potom dorađen te je primijenjen na problem izrade rasporeda laboratorijskih vježbi za kolegije Digitalna logika i Objektно orijentirano programiranje održane akademske godine 2018./ 2019. na Fakultetu elektrotehnike i računarstva prema FER2 programu. Algoritam je uspješno rasporedio studente u termine laboratorijskih vježbi tako da niti jedan student nema koliziju te da niti jedan termin nije prepunjen.

U daljnjem radu se preporučuje paraleliziranje postupka uzorkovanja s ciljem smanjenja vremena potrebnog za automatsko testiranje. Također se preporučuje dodatno eksperimentirati s heuristikom iz poglavlja 5.4.2 kako bi se utvrdila vrijednost vjerojatnosti koju treba redistribuirati te trenutak u kojem treba uključiti heuristiku u rad algoritma.

LITERATURA

Zijun Wu i Michael Kolonko. Asymptotic properties of a generalized cross-entropy optimization algorithm. *IEEE Trans. Evolutionary Computation*, 18(5):658–673, 2014. doi: 10.1109/TEVC.2014.2336882. URL <https://doi.org/10.1109/TEVC.2014.2336882>.

Marko Čupić. *Prirodom inspirirani optimizacijski algoritmi. Metaheuristike*. 2013. URL <http://java.zemris.fer.hr/nastava/pioa/knjiga-0.1.2013-12-30.pdf>.

Marko Čupić. Evolucijsko računanje i problem izrade rasporeda. 06 2019. URL https://www.researchgate.net/publication/268047044_Evolucijsko_racunanje_i_problem_izrade_rasporeda.

Primjena konstruktivnog optimizacijskog algoritma na problem rasporeda studenata

Sažetak

U ovome radu su opisani pojedini optimizacijski algoritmi. Potom je opisan konstruktivistički optimizacijski algoritam. Nakon toga slijedi formalna specifikacija problema izrade rasporeda laboratorijskih vježbi na Fakultetu elektrotehnike i računarstva. Opisani konstruktivistički algoritam je implementiran i primijenjen na specificirani problem. Ulaz algoritma su strukturirano navedeni studenti i njihovi rasporedi te termini laboratorijskih vježbi, a izlaz je generirani raspored. Provedena je analiza algoritma te su prikazani utjecaji različitih kriterija na rad algoritma.

Ključne riječi: optimizacijski problemi, problem izrade rasporeda, konstruktivistički optimizacijski algoritmi.

Application of Constructive Optimization Algorithm On Student Scheduling

Abstract

This thesis describes few optimization algorithms. Description of Generalized Cross-Entropy Optimization Algorithm is given afterwards. There is a formal specification of the scheduling problem for laboratory exercises on Faculty of Electrical Engineering and Computing. Described Generalized Cross-Entropy Optimization Algorithm is implemented and applied to specified problem. Algorithm input is structured representation of students schedules and laboratory exercises and output is students schedules. The algorithm is analyzed and influence of various parameters is presented.

Keywords: optimization problems, scheduling problems, Cross-Entropy Optimization Algorithm.